李文

男 | 23 | 求职意向：AI Infra

15035202407 | leeven8888@163.com

教育背景

浙江大学 (985，杭州) 2023.09-至今

- 电子信息，大数据技术与工程，硕士

电子科技大学 (985，成都) 2019.09-2023.06

- 计算机科学与工程学院，数据科学与大数据技术，本科

实习经历

美团 AI Infra 实习生（核心本地商业/基础研发平台/计算和智能平台部） 2024.05-至今

- 改写 Flash Attention Cuda Kernel 适配多模态模型混合训练，单算子 MFU 从 27% 提升到 54%；
- 使用 TensorRT 加速优化自研文生图模型推理部署，使推理速度提升约 1.3 倍；
- 调研开源文本大模型推理框架，并参与公司内部多模态大模型推理框架开发，目前已支持 SD、Flux、Qwen2-VL 等多种开源多模态模型，实现快速部署推理。

项目经历

基于 FFT 进行卷积加速的并行算法实现 2023.10-2024.3

- 项目描述：使用 Cuda 并行模型实现并行 FFT 运算，对卷积核和一维被卷序列进行处理。通过 profile 分析性能瓶颈并进行优化
- 职责与成果：实现了高效的基于 FFT 操作的卷积运算并行算法，针对长度为 1000000 的一维序列，使用长度为 401 卷积核，单卷积核执行时间从 0.6ms 降低到 0.056ms。并实际运用在声音信号处理系统中

基于文本提示的图像编辑系统 2022.10 - 2023.6

- 项目描述：复现并重新训练图像编辑模型 StyleCLIP，使用 triton inference server 对预训练模型进行部署，搭建网站提供编辑服务
- 职责与成果：实现了响应快、延迟低的图像编辑系统。相较于直接调用模型进行推理，响应时间缩短了约 40%。本科毕业设计成绩 90+

系统文件备份软件 2022.10-2022.11

- 项目描述：设计并实现了一款基础数据备份软件，实现了文件压缩、文件加密、元数据备份与恢复、用户界面等功能
- 职责与成果：开发 huffman 算法实现文件压缩功能，文件大小相较于直接备份缩小 60%；使用 AES 加密算法对文件内容加密，实现备份文件加密功能；使用 chmod 等内核函数接口实现文件元数据备份和恢复功能；

专业技能

技能方向

- 了解 Cuda 编程和并行计算；
- 了解 TensorRT、TensorRT-LLM、vLLM 等推理方案；
- 了解深度学习和大模型；
- 熟悉 C/C++，面向对象等，了解 Python 等语言；
- 熟悉常见数据结构，数组、栈与队列、树等；
- 熟悉 Linux 操作系统，熟练使用 git、docker、cmake 等。

奖励荣誉

校内获奖 本科阶段

- 校一等奖学金 × 3
- 校优秀毕业生